
Agregiranje podataka

— Union, join i broadcast* —

Union

- Kao operacija unije nad dva skupa podataka
- Možemo posmatrati kao konkatenciju dve tabele na nivou redova
- Prije upotrebe operacije unije potrebno prvo podatke transformisati tako da imaju istu strukturu
- Više različitih sistema koji prikupljaju slične podatke za analizu - potrebno agregirati i analizirati sve podatke istovremeno
- Primjer - lanac prodavnica gdje svaka prikuplja informacije o svojim prodajama - potrebno napraviti generalni mjesečni izvještaj koristeći podatke

Join

- Kombinacija podataka koji imaju različitu strukturu na osnovu zajedničkog ključa (kolone)
- Koristi se nad PairRDD
- Bitno da data kolona pod istim nazivom postoji u oba slučaja,
- Kreira parove ključ-vrijednost:
 - ključ - vrijednost u koloni na osnovu koje se vrši join
 - vrijednost - konkatenirane vrijednosti iz oba skupa podataka koje su vezane za taj ključ
- Primjer - različiti dijelovi sistema prikupljaju različite informacije o istim entitetima - sistem za skladište prati koji artikli su u narudžbi tok sistem za plaćanje prati cijenu narudžbe

Agregacija i shuffling

- Operacija unije ne proizvodi shuffling - podaci i dalje mogu ostati na istim particijama, samo se dalje operacije primjenjuju na obe particije
- Join - značajan shuffling potrebno podatke iz dva skupa podataka grupisati na nivou ključa (slično kao groupBy)
- U slučaju DataFrame API-ja join puno optimizovaniji zbog column based pristupa
- Isti API postoji i za DataFrame API kao i u RDD slučaju

Explode

- Operacija specifična za DataFrame API
- Ponašanje slično kao flatMap u RDD API-ju
- U slučaju kada imamo kolonu čija je vrijednost neka kolekcija
- Upotrebom explode operacije kreira se novi red u DataFrame-u za svaku vrijednost u kolekciji