


Performanse računarskih sistema – Peta laboratorijska vježba

U ovoj laboratorijskoj vježbi izvršena je analiza $M/M/c$ sistema koji se sastoji od jednog reda čekanja i c servera. Ovi sistemi predstavljaju proširenje $M/M/1$ sistema na slučaj s više servera i opisuju se Kendall-ovom notacijom $A/S/c$, gdje M označava Markovljev (eksponencijalni) proces pristizanja poslova i usluživanja. Pretpostavka je da je prosječno pristizanje poslova u red λ i da je broj poslova prisutnih u sistemu n (poslovi koji se nalaze u redu i koji se obrađuju na serverima). Prosječno usluživanje poslova na svakom od servera je μ . Prosječno usluživanje sistema je tada $n\mu$ ($n \leq c$).

Prema Kendall-ovoj notaciji, $M/M/c$ sistem pretpostavlja: eksponencijalnu raspodjelu vremena između dolazaka poslova, eksponencijalnu raspodjelu vremena usluživanja, c identičnih servera, beskonačan kapacitet sistema ($B = \infty$), beskonačan broj potencijalnih poslova ($N = \infty$), te FCFS disciplinu usluživanja (eng. *First Come, First Served*).

Dijagram stanja $M/M/c$ sistema



Kao i kod $M/M/1$ sistema, analiza se zasniva na procesu rođenja i smrti (eng. *birth-death process*). Tok sistema se opisuje tranzicijama između stanja, gdje stanje n označava ukupan broj poslova u sistemu. Na osnovu toga, vjerovatnoća da se u sistemu nalazi n poslova je:

$$P_n = \begin{cases} \frac{(c\rho)^n}{n!} P_0, & n = 1, 2, \dots, c \\ \frac{(c\rho)^n}{c! c^{n-c}} P_0, & n > c \end{cases}$$

Intenzitet saobraćaja kod ovih sistema je $\rho = \lambda / (c\mu)$. Ovaj parametar mora biti manji od 1 ($\rho < 1$) kako bi sistem bio u stabilnom stanju. Za razliku od $M/M/1$ sistema gdje je uslov stabilnosti $\rho = \lambda / \mu < 1$, ovdje je dovoljno da ukupno opterećenje sistema ne premaši kapacitet svih servera zajedno. Suma svih vjerovatnoća je jednaka jedinici i na taj način dolazimo do vrijednosti P_0 :

$$\sum P_n = \sum \frac{(c\rho)^n}{n!} P_0 + \sum \frac{(c\rho)^n}{c! c^{n-c}} P_0 = 1$$

$$P_0 = \frac{1}{\sum_{n=0}^{c-1} \frac{(c\rho)^n}{n!} + \frac{(c\rho)^c}{c! (1 - \rho)}}$$

Uvrštavanjem P_0 u P_n dobijamo izraz koji zavisi samo od intenziteta saobraćaja ρ i broja servera c . Značajna vjerovatnoća je ona koja nam govori da li su svi serveri zauzeti:

$$P(K \geq c) = \sum_{n=c}^{\infty} P_n = P_0 \frac{(c\rho)^c}{c!} \sum \rho^{n-c} = \frac{(c\rho)^c}{c! (1-\rho)} P_0$$

Ova formula se zove *Erlang-ova C formula* i označava se sa κ . Novi posao koji pristiže u sistem smješta se u red ako su svi serveri zauzeti.

Prosječan broj poslova u sistemu

Prosječan broj poslova u sistemu računamo pomoću matematičkog očekivanja:

$$E[n] = \sum n P_n = \frac{(c\rho)^c \rho P_0}{c! (1-\rho)^2} + c\rho = c\rho + \frac{\rho\kappa}{1-\rho}$$

Prosječan broj poslova u redu čekanja

Formula za prosječan broj poslova koji čekaju u redu je:

$$q = \sum_{n=c+1}^{\infty} (n-c) P_n = \frac{\rho(c\rho)^c}{c! (1-\rho)^2} P_0 = \frac{\rho\kappa}{1-\rho}$$

Prosječno odzivno vrijeme sistema

Koristeći Little-ov zakon možemo izračunati prosječno odzivno vrijeme sistema. Little-ov zakon kaže da je prosječan broj poslova u sistemu jednak proizvodu prosječnog odzivnog vremena i prosječne stope pristizanja ($E[n] = \lambda \cdot r$). Na osnovu toga:

$$r = \frac{E[n]}{\lambda} = \frac{1}{\mu} + \frac{\kappa}{c\mu(1-\rho)}$$

Prosječno vrijeme čekanja posla u redu

Prosječno vrijeme čekanja posla u redu je:

$$w = \frac{q}{\lambda} = \frac{\rho\kappa}{1-\rho} \cdot \frac{1}{\lambda} = \frac{\kappa}{c\mu(1-\rho)}$$

Zaključak

Na osnovu izvedenih formula mogu se izvesti zaključci o performansama $M/M/c$ sistema. Može se primjetiti da će performanse ovakvih sistema biti bolje sa porastom broja servera c . Prosječno odzivno vrijeme r i prosječno vrijeme čekanja posla u redu w bi se tada smanjilo, što je direktna prednost sistema s više servera u poređenju s $M/M/1$ sistemom.

S druge strane, porastom intenziteta saobraćaja ρ performanse bi bile lošije i imali bi rast r , w i q . Kada intenzitet saobraćaja teži ka 1 ($\rho \rightarrow 1$), svi posmatrani parametri teže ka beskonačnosti, što je analogno ponašanju $M/M/1$ sistema.

Koristeći Erlang-ovu C formulu (κ), možemo precizno odrediti vjerovatnoću čekanja u redu i optimizovati broj servera za date zahtjeve performansi. Ovo je posebno korisno pri dimenzionisanju računarskih sistema i mrežne infrastrukture gdje su poznate stope dolazaka zahtjeva i kapaciteti usluživanja.